

Code ▼

PCA and LDA

Jovanni Ochoa

Run PCA on the bank data

c(1, 6, 8, 12, 13)]

Hide

```
library(stats)

# Load data
bank <- read.csv("desktop/bank-full.csv", header=TRUE)

i <- sample(1:15000, 10000, replace=FALSE)
train <- bank[i,]
test <- bank[-i,]

# Apply pre-processing to remaining columns
set.seed(1234)
pca_out <- preProcess(train[c(1, 6, 8, 12, 13)], method=c("center", "scale", "pca"))
pca_out
```

Created from 10000 samples and 5 variables

Pre-processing:


- centered (4)
- ignored (1)
- principal component signal extraction (4)
- scaled (4)

PCA needed 4 components to capture 95 percent of the variance

PCA plot

Hide

```
train_pc <- predict(pca_out, train[c(1, 6, 8, 12, 13)])
test_pc <- predict(pca_out, test[,])
plot(test_pc$PC1, test_pc$PC2, pch=ifelse(test_pc$loan == "yes", 8, 9), col=ifelse(test_
pc$loan == "yes", "green", "red"))
```



PCA data in knn

Now let's see if our two principal components can predict class.

Hide

```
train_df <- data.frame(train_pc$PC1, train_pc$PC2, train$loan)
test_df <- data.frame(test_pc$PC1, test_pc$PC2, test$loan)
library(class)
set.seed(1234)
pred <- knn(train=train_df[,1:2], test=test_df[,1:2], cl=train_df[,3], k=3)
mean(pred==test$loan)
```

```
[1] 0.78484
```

With the decision tree we got a little lower accuracy.

LDA

Hide

```
library(MASS)

#check the levels of each column
sapply(test, function(x) length(unique(x)))
```

	age	job	marital	education	default	balance	housing	loan	contac
t	day	month							
3	77	12	3	4	2	6534	2	2	
	31	12							
	duration	campaign	pdays	previous	poutcome	Target			
	1493	41	559	41	4	2			

Hide

```
lda1 <- lda(loan ~ job + marital + education + default + balance + housing + day + month
+ duration + campaign, data = test)
lda1$means
```

```
      jobblue-collar jobentrepreneur jobhousemaid jobmanagement jobretired jobself-employed
d jobservices  jobstudent
no      0.1878914      0.02846332   0.02792754      0.2322272 0.05588856      0.0373036
9 0.08107022 0.028161940
yes      0.2155946      0.05142109   0.02056844      0.1851159 0.04244577      0.0330964
8 0.10976066 0.001869858
      jobtechnician jobunemployed   jobunknown maritalmarried maritalsingle educationsecon
dary educationtertiary
no      0.1724542      0.03348625 0.0066637645      0.5869805      0.3024478      0.487
3924      0.3306433
yes      0.1851159      0.01645475 0.0005609574      0.6389304      0.2324233      0.589
1922      0.2638369
      educationunknown defaultyes   balance housingyes      day monthaug      monthdec   mo
nthfeb   monthjan   monthjul
no      0.04259451 0.01208854 1541.8516   0.5029970 16.04735 0.1889629 0.006797710 0.07
564545 0.03988213 0.1251381
yes      0.01608078 0.04188482  816.5361   0.5946148 16.73859 0.1129394 0.002056844 0.07
292446 0.03964099 0.2683246
      monthjun   monthmar   monthmay   monthnov   monthoct   monthsep duration campaign
no 0.06857985 0.015102301 0.2438134 0.1086294 0.02287111 0.018383953 260.6689 2.719854
yes 0.05703067 0.004861631 0.2236350 0.1357517 0.01028422 0.005609574 247.0150 2.887809
```

predict on test

Hide

```
### predict on test
lda_pred <- predict(lda1, newdata=test, type="class")
lda_pred$class
```

[1]	no	no	no	no	no	yes	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[29]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[57]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[85]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[113]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[141]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[169]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[197]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	yes	no	no	n
o	no	no	no	no	no	no															
[225]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[253]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[281]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[309]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[337]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[365]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[393]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[421]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[449]	no	no	no	no	yes	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[477]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[505]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[533]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[561]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[589]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[617]	no	no	no	no	no	no	no	no	yes	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[645]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															
[673]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	yes	no	no	no	no	no	n
o	no	no	no	no	no	no															
[701]	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	no	n
o	no	no	no	no	no	no															

```

[ 729] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 757] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 785] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 813] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 841] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 869] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 897] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 925] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 953] no no no no no no no no no no no no no no no no no no no no no n
o no no no no no no no
[ 981] no no no no no no no no no no no no no no no no no no no no
[ reached getOption("max.print") -- omitted 34211 entries ]
Levels: no yes

```

Hide

```
mean(lda_pred$class==test$loan)
```

```
[1] 0.84786
```

plot

Hide

```
plot(lda_pred$x[,1], rep(0,length(lda_pred$x[,1])), pch=c(23,21)[unclass(lda_pred$class)],
bg=c("red","green")[unclass(test$loan)])
```

